

Συνοπτική Αναφορά Υλοποίησης Αξιολόγηση Αρχιτεκτονικών H-ACN, ResNet και ACN

Ονοματεπώνυμο: Ευαγγελάτος Σπυρίδων
Αριθμός Μητρώου: 03400290

Αύγουστος 2026

1 Στόχος της Πειραματικής Διαδικασίας

Στόχος του πειράματος ήταν η υλοποίηση και η συγκριτική αξιολόγηση τριών αρχιτεκτονικών (ResNet, ACN και Hybrid-ACN) σε ένα πρόβλημα ιεραρχικής σύνθεσης δεδομένων. Συγκεκριμένα, αξιολογήσαμε την ικανότητα των μοντέλων να μάθουν τους κανόνες μιας συνθετικής γραμματικής μέσω του Random Hierarchy Model (RHM).

2 Πειραματική Διάταξη και Παράμετροι

Για τη διεξαγωγή του πειράματος κατασκευάστηκε ένα σύνολο δεδομένων 20.000 δειγμάτων (10.000 για εκπαίδευση, 10.000 για έλεγχο) χρησιμοποιώντας το **seed 15**, το οποίο αντιστοιχεί σε μια "εύκολη" γραμματική. Το μήκος της κάθε ακολουθίας ορίστηκε στο 16.

Χρησιμοποιήθηκε ένα δίκτυο αρχιτεκτονικής Transformer με τα εξής χαρακτηριστικά:

- **Αριθμός Επιπέδων (Layers):** 8
- **Διάσταση (d_model):** 128
- **Κεφαλές Προσοχής (Attention Heads):** 4
- **Διάσταση FeedForward (Hidden Factor):** 512

Αρχικά, οι υλοποιήσεις βασίστηκαν σε απλή κανονικοποίηση (Simple Layer Normalization). Στη συνέχεια, εφαρμόστηκε η τεχνική Adaptive Layer Normalization (DepthLN) που αναφέρεται στο appendix D του paper για την επίδραση στη διαμόρφωση των αρχιτεκτονικών παραμέτρων α του H-ACN.

Η εκπαίδευση διήρκεσε 120 εποχές (περίπου 20.000 steps) με τα παρακάτω hyperparameters βελτιστοποίησης:


- **Optimizer:** AdamW
- **Ρυθμός Μάθησης (Learning Rate):** 10^{-3} με Cosine Annealing Scheduler
- **Regularization:** Dropout (0.2) και Weight Decay (0.01)
- **Batch Size:** 64

3 Αποτελέσματα


Τα μοντέλα εκπαιδεύτηκαν πλήρως και τα τελικά ποσοστά ακρίβειας στο test set παρατίθενται στον παρακάτω πίνακα, συμπεριλαμβανομένης και της βελτιωμένης έκδοσης με το DepthLN:

Αρχιτεκτονική / Αρχικοποίηση	Ακρίβεια (Test Accuracy)
ResNet (Σταθερό $\alpha = 1.0$)	92.51%
H-ACN ($\alpha_0 = 1.0$ - Simple LN)	89.00%
H-ACN ($\alpha_0 = 0.5$ - DepthLN)	89.00%
H-ACN ($\alpha_0 = 0.5$ - Simple LN)	86.65%
ACN (Σταθερό $\alpha = 0.0$)	69.45%


Πίνακας 1: Τελική Ακρίβεια ανά Αρχιτεκτονική (120 epochs)




Σχήμα 1: Εξέλιξη Ακρίβειας και Alpha Profile για το ResNet (120 epochs)



Σχήμα 2: Εξέλιξη Ακρίβειας και Alpha Profile για το H-ACN με $\alpha_0 = 1.0$ (120 epochs)



Σχήμα 3: Εξέλιξη Ακρίβειας και Alpha Profile για το H-ACN με $\alpha_0 = 0.5$ (120 epochs)



Σχήμα 4: Εξέλιξη Ακρίβειας και Alpha Profile για το H-ACN με $\alpha_0 = 0.5$ και χρήση DepthLN (120 epochs)

4 Συμπεράσματα

Από τα παραπάνω αποτελέσματα εξάγονται τα εξής συμπεράσματα:

1. Σε αντίθεση με την αρχική προσδοκία της βιβλιογραφίας, η καθιερωμένη αρχιτεκτονική **ResNet παρουσίασε την υψηλότερη απόδοση** με διαφορά περίπου 3%. Η σταθερότητα των παραμέτρων της ($\alpha = 1$) επέτρεψε στο δίκτυο να αξιοποιήσει άμεσα τις τοπικές διασυνδέσεις χωρίς να αναλώνει χρόνο εκπαίδευσης στην αναζήτηση της βέλτιστης αρχιτεκτονικής.
2. Το χαμηλό ποσοστό (69.45%) του ACN επιβεβαιώνει ότι οι κοντές συνδέσεις είναι απολύτως απαραίτητες για προβλήματα ιεραρχικής σύνθεσης.
3. Η χρήση απλής κανονικοποίησης (Simple Layer Normalization) στο H-ACN με $\alpha_0 = 0.5$ οδήγησε σε χαμηλότερη απόδοση (86.65%) και στον σχηματισμό ενός τεχνητού "U-shape" attractor.
4. Η εισαγωγή της **Adaptive Layer Normalization (DepthLN)** αποδείχθηκε κρίσιμη για την ορθή λειτουργία του H-ACN ($\alpha_0 = 0.5$). Ο παράγοντας ενίσχυσης του DepthLN αντιστάθμισε το weight decay, επιτρέποντας στα α να σχηματίσουν το αναμενόμενο φυσιολογικό (μονότονα φθίνον) προφίλ. Αυτή η μαθηματική προσθήκη αύξησε σημαντικά την ακρίβεια του μοντέλου από 86.65% σε 89.00%.